


人工智能

群体智能

Swarm Intelligence

卜晨阳



群智能



鸟群

群智能



鱼群

群智能



蜂群

群智能



蚁群

“群”的特征



- 相互作用的相邻个体的集合
- 个体的行为简单
 - 既有竞争又有协作
- 智能化的集体行为
 - 个体间不仅能够交互信息，还能够处理信息，根据信息改变自身行为。
 - 没有一个集中控制中心，分布式、自组织。
 - 作为群体协同工作时，能够突现出非常复杂的行为特征——智能。

群智能的起源和发展

1989年，加利福尼亚大学的教授贝尼在其元胞自动机系统中**首次提出群智能**的概念



贝尼(Beni)

任何一种由昆虫群体或其它动物社会行为机制而激发设计出的算法，或分布式解决问题的策略均属于群智能

——伯纳堡等，《群智能：从自然到人工系统》，1999



伯纳堡(Bonabeau)

无智能或简单智能的**主体**，通过任何形式的**聚集协同而表现出智能行为**的特性 ——伯纳堡

群智能的起源和发展

- 2001年，肯尼迪和艾伯哈特出版了《群体智能》一书
 - 群智能发展的里程碑
 - 赞同伯纳堡关于群智能定义的基本精神，但反对“**主体**”一词，认为会限制“群”的定义范围
 - 最重要观点：智能源于**社会性的相互作用**
 - 群智能发展的基石
 - 群智能已成为有别于传统人工智能中连接主义和符号主义的一种新的关于智能的描述方法



艾伯哈特(Eberhart)

基于群智能的优化算法

■ 典型算法

- 蚁群算法（蚂蚁觅食）
- 粒子群算法（蜂群或鸟群觅食）

■ 优点

- 灵活性
- 稳健性
- 自组织
- 潜在的并行性和分布式



已有的群智能理论和应用研究证明群智能方法是一种能够有效解决大多数优化问题的新方法

群智能

特点

分布式：无中心控制

随机性：非确定性

自适应：个体根据环境进行策略调整

正反馈：个体好的尝试会对个体产生正反馈

自发涌现：会在群体层面涌现出一种智能

群智能

代表性方法

蚁群优化算法

粒子群优化算法

蚁群算法

- 1992年由意大利学者多里戈提出
 - 模拟自然界中蚂蚁寻找从巢穴到食物的最佳路径的行为
 - 一种新型的优化算法




多里戈 (Dorigo)

蚂蚁如何搜索路径？

蚁群寻食


等长路径的情形



选择走路径1的蚂蚁和选择走路径2的蚂蚁数目相近

蚁群寻食


不等长路径的情形



结果如何呢？

蚁群寻食


不等长路径的情形



绝大多数蚂蚁选择长度较短的路径


蚁群寻食过程分析

蚂蚁从A点出发，速度相同，食物在D点，可能随机选择路线ABD或ACD。



假设初始时每条路线分配一只蚂蚁，每个时间单位行走一步，本图为经过9个时间单位时的情形：
走ABD的蚂蚁已到达终点，而走ACD的蚂蚁刚好走到C点，为一半路程。

蚁群寻食过程分析



经过18个时间单位时的情形：
走ABD的蚂蚁到达终点后得到食物又返回了起点A，而
走ACD的蚂蚁刚好走到D点。

蚁群寻食过程分析

假设蚂蚁每经过一处所留下的信息素为一个单位，则经过36个时间单位后，所有开始一起出发的蚂蚁都经过不同路径从D点取得了食物，此时ABD的路线往返了2趟，每一处的信息素为4个单位，而ACD的路线往返了一趟，每一处的信息素为2个单位，其比值为2:1。

寻找食物的过程继续进行，则按信息素的指导，蚁群在ABD路线上增派一只蚂蚁（共2只），而ACD路线上仍然为一只蚂蚁。再经过36个时间单位后，两条路线上的信息素单位积累为12和4，比值为3:1。

蚁群寻食过程分析

若按以上规则继续，蚁群在ABD路线上再增派一只蚂蚁（共3只），而ACD路线上仍然为一只蚂蚁。再经过36个时间单位后，两条路线上的信息素单位积累为24和6，比值为4: 1。


若继续进行，则按信息素的指导，最终所有的蚂蚁会放弃ACD路线，而都选择ABD路线。

蚁群优化算法

ACO: Ant Colony Optimization

一种解空间搜索方法

适用于在图上寻找最优路径



A. Coloni, M. Dorigo et V. Maniezzo, Distributed Optimization by Ant Colonies, actes de la première conférence européenne sur la vie artificielle, Paris, France, Elsevier Publishing, 134-142, 1991.

蚁群优化算法

形式化

每个蚂蚁对应一个计算智能体

蚂蚁依概率选择候选位置进行移动

在经过的路径上留下“信息素” (Pheromone)

“信息素”随时间挥发

“信息素”浓度大的路径在后续的选择中会以更高的概率被选取

旅行商问题的蚁群优化求解

旅行商问题 (TSP: Traveling Salesman Problem)

n 个城市的有向图 $G = (V, E)$

$$V = \{1, 2, \dots, n\} \quad E = \{(i, j) | i, j \in V\}$$

城市之间的距离表示为

d_{ij} 为节点 i 和 j 之间的距离

目标函数

$$f(w) = \sum_{l=1}^{n-1} d_{i_l i_{l+1}}$$

$w = (i_1, i_2, \dots, i_n)$ 为TSP问题的任意可行解

旅行商问题的蚁群优化求解

首先将 m 只蚂蚁随机放置在 n 个城市， t 时刻位于城市 i 的第 k 只蚂蚁选择下一个城市 j 的概率为：

$$p_{ij}^k(t) = \begin{cases} \frac{(\tau_{ij}(t))^\alpha (\eta_{ij}(t))^\beta}{\sum_{k \in allowed} (\tau_{ik}(t))^\alpha (\eta_{ik}(t))^\beta} & j \in allowed \\ 0, & otherwise \end{cases}$$

$\tau_{i,j}(t)$ 表示 (t) 时刻边 (i,j) 上的信息素浓度；

$\eta_{i,j}(t) = 1/d_{ij}$ 是根据距离定义的启发信息；

α 和 β 反映了信息素与启发信息的相对重要性；

旅行商问题的蚁群优化求解

当所有蚂蚁完成周游后，按以下公式进行信息素更新

$$\Delta\tau_{ij}^k = f(x) = \begin{cases} \frac{Q}{L_k}, & ij \in w_k \\ 0, & otherwise \end{cases}$$

$$\Delta\tau_{ij} = \sum_{k=1}^m \Delta\tau_{ij}^k$$

$$\tau_{ij}(t+1) = \rho \cdot \tau_{ij}(t) + \Delta\tau_{ij}$$

其中：Q为常数， w_k 表示第k只蚂蚁在本轮迭代中走过的路径， L_k 为路径长度，

ρ 为小于1的常数，反映信息素挥发速度

旅行商问题的蚁群优化求解

TSP问题蚁群算法流程

(1)初始化 随机放置蚂蚁,

(2)迭代过程

$k=1$

while $k < \text{ItCount}$ do (执行迭代)

 for $i = 1$ to m do (对 m 只蚂蚁循环)

 for $j = 1$ to $n - 1$ do (对 n 个城市循环)

 采用轮盘赌方法选择下一个城市 j ;

 蚂蚁转移到 j ;

 end for

 end for

 计算每只蚂蚁的路径长度;

 更新所有蚂蚁路径上的信息量;


$k = k + 1$;

end while

(3)输出结果, 结束算法.


旅行商问题的蚁群优化求解

旅行商问题 (TSP: Traveling Salesman Problem)




节点间距离: $d_{AB}=100; d_{BC}=60 \cdots; d_{DE}=150$

April 15, 2020




旅行商问题的蚁群优化求解

第 t 轮：第0步




旅行商问题的蚁群优化求解

第 t 轮：第1步




旅行商问题的蚁群优化求解

第 t 轮：第2步




旅行商问题的蚁群优化求解

第 t 轮：第3步



旅行商问题的蚁群优化求解

第 t 轮：第4步



旅行商问题的蚁群优化求解

计算路径长度



[A,D,C,E,B]

$$L_1 = d_{AD} + d_{DC} + d_{CE} + d_{EB}$$



[B,C,D,A,E]

$$L_2 = d_{BC} + d_{CD} + d_{DA} + d_{AE}$$



[C,B,E,D,A]

$$L_3 = d_{CB} + d_{BE} + d_{ED} + d_{DA}$$



[D,E,A,B,C]

$$L_4 = d_{DE} + d_{EA} + d_{AB} + d_{BC}$$



[E,A,B,C,D]

$$L_5 = d_{EA} + d_{AB} + d_{BC} + d_{CD}$$

旅行商问题的蚁群优化求解

蚁群大小


一般情况下，蚁群中的蚂蚁个数不超过TSP图中节点的个数

终止条件


设定迭代轮数

设定最优解连续保持不变的迭代轮数


旅行商问题的蚁群优化求解




1



2



3



4

- 蚂蚁在这些城市点之间移动
- 两城市之间的信息素越多，蚂蚁就越有可能选择他们之间的路径
- 能够成功完成遍历的蚂蚁会在路径上留下信息素，路越短，留下的信息素越多

蚁群优化算法小结

思想

局部随机搜索+自增强

鲁迅：“世界本无路，走的人多了也就有了路”

缺点

收敛速度慢

易于陷入局部最优

对于解空间为连续的优化问题不适用

群智能

代表性方法

蚁群优化算法

粒子群优化算法

粒子群优化算法

粒子群优化算法是一种基于种群寻优的启发式搜索算法。在1995年由Kennedy和Eberhart首先提出来的。

它的主要启发来源于对**鸟群群体运动行为**的研究。我们经常可以观察到鸟群表现出来的同步性，虽然每只鸟的运动行为都是互相独立的，但是在整个鸟群的飞行过程中却表现出了高度一致性的复杂行为，并且可以自适应的调整飞行的状态和轨迹。

鸟群具有这样的复杂飞行行为的原因，可能是因为每只鸟在飞行过程中都**遵循了一定的行为规则**，并能够**掌握邻域内其它鸟的飞行信息**。

粒子群优化算法

粒子群优化算法借鉴了这样的思想，每个粒子代表待求解问题搜索解空间中的一个潜在解，它相当于一只鸟，“飞行信息”包括粒子当前的位置和速度两个状态量。

每个粒子都可以获得其邻域内其它个体的信息，对所经过的位置进行评价，并根据这些信息和位置速度更新规则，改变自身的两个状态量，在“飞行”过程中传递信息和互相学习，去更好地适应环境。


随着这一过程的不断进行，粒子群最终能够找到问题的近似最优解。

粒子群优化算法

PSO: Particle Swarm Optimization

一种随机优化方法

通过粒子群在解空间中进行搜索，寻找最优解（适应度最大的解）



粒子群优化算法

构成要素

粒子群

每个粒子对应所求解问题的一个可行解

粒子通过其位置和速度表示

粒子 i 在第 n 轮的位置: $x_n^{(i)}$

粒子 i 在第 n 轮的速度: $v_n^{(i)}$


记录

$p_{best}^{(i)}$: 粒子 i 的历史最好位置

g_{best} : 全局历史最好位置

计算适应度的函数

适应度: $f(x)$



粒子群优化算法

算法过程描述

初始化

初始化粒子群：每个粒子的位置和速度，即 $x_0^{(i)}$ 和 $v_0^{(i)}$

$p_{best}^{(i)}$ 和 g_{best}

循环执行如下三步直至满足结束条件

计算每个粒子的适应度： $f(x_n^{(i)})$

更新每个粒子历史最好适应度及其相应的位置，更新当前全局最好适应度及其相应的位置


更新每个粒子的速度和位置

$$v_{n+1}^{(i)} = v_n^{(i)} + c_1 * r_1 * (p_{best}^{(i)} - x_n^{(i)}) + c_2 * r_2 * (g_{best} - x_n^{(i)})$$

$$x_{n+1}^{(i)} = x_n^{(i)} + v_{n+1}^{(i)}$$

粒子群优化算法

粒子位置和速度更新示例



粒子群优化算法

粒子速度更新公式解读

$$v_{n+1}^{(i)} = v_n^{(i)} + c_1 * r_1 * (p_{best}^{(i)} - x_n^{(i)}) + c_2 * r_2 * (g_{best} - x_n^{(i)})$$

①惯性项

保持原速度不变的倾向

②记忆项

回到历史最好位置的倾向

③社会项

走向粒子群全局最好位置的倾向

粒子群优化算法

粒子速度更新公式解读

$$v_{n+1}^{(i)} = v_n^{(i)} + \boxed{c_1} * \boxed{r_1} * (p_{best}^{(i)} - x_n^{(i)}) + \boxed{c_2} * \boxed{r_2} * (g_{best} - x_n^{(i)})$$

权重参数：一般取值为2

随机参数：0和1之间的随机数

粒子群优化算法

算法终止条件

迭代的轮数

最佳位置连续未更新的轮数

适应度函数的值到达预期要求

粒子群优化算法

速度更新参数分析

又称加速度参数，用来控制粒子当前最优位置 $p_{best}^{(i)}$ 和粒子群当前最优位置 g_{best} 对粒子飞行速度的影响

$c_1 > 0, c_2 = 0$ 每个微粒执行局部搜索；

$c_1 = 0, c_2 > 0$ 微粒群转化为一个随机爬山法；

$c_1 = c_2 > 0$ ：微粒逐渐移向 \bar{p}_g 和 \bar{p}_i 的加权均值；

$c_2 > c_1$ ： 算法比较适合于单峰优化问题；

$c_1 > c_2$ ： 算法比较适合于多峰优化问题。

粒子群优化算法改进

惯性权重

速度冲量导致微粒按照先前速度方向继续移动。Yuhui Shi [1] 提出一个惯性权重 w 来控制先前微粒速度的影响

惯性权重

$$v_{n+1}^{(i)} = w * v_n^{(i)} + c_1 * r_1 * (p_{best}^{(i)} - x_n^{(i)}) + c_2 * r_2 * (g_{best} - x_n^{(i)})$$

[1] Y. Shi, R. Eberhart. "A modified particle swarm optimizer," Proceedings of IEEE World Congress on Computational Intelligence, Anchorage, AK, 1998, pp. 69-73.

粒子群优化算法

和遗传算法相比

遗传算法强调“适者生存”，不好的个体在竞争中被淘汰；**PSO**强调“协同合作”，不好的个体通过学习向好的方向转变。

遗传算法中最好的个体通过产生更多的后代来传播基因；**PSO**中的最好个体通过吸引其它个体向它靠近来施加影响。

遗传算法的选择概率只与上一代群体相关，而与历史无关，群体的信息变化过程是一个Markov链过程；而**PSO**中的个体除了有位置和速度外，还有着过去的历史信息（pBest、gBest）。

粒子群优化算法

优点

易于实现;

可调参数较少;

所需种群或微粒群规模较小;

计算效率高, 收敛速度快。

粒子群优化算法

缺点

和其它演化计算算法类似，**不保证收敛**到全局最优解

数学**理论基础相对薄弱**，涉及的各种参数设置没有确切的理论依据。

带有**随机性**，每次的求解不一定一样。当处理突发事件时，系统的反应可能是不可测的，这在一定程度上增加了其应用风险。

粒子群优化算法小结

一种随机优化算法

适用于求解连续解空间的优化问题

谢谢大家